

UNIVERSITÉ DE MONS
FACULTÉ DES SCIENCES

Améliorer les prédictions d'un réseau de neurones sur base d'explications a priori

Mémoire effectué dans le cadre du **Master en Sciences Informatiques, finalité spécialisée.**

Nicolas Melaerts

Directeur : Pierre Vandenhove Co-directeur : Stéphane Dupont

Année académique 2025–2026

Résumé

Les réseaux de neurones convolutifs sont devenus l'outil standard pour la classification d'images, mais leur opacité rend difficile la détection des raccourcis qu'ils peuvent apprendre lorsque la classe est associée par hasard à un détail accessoire de l'image. Un exemple classique est celui d'un modèle entraîné à distinguer loups et huskys qui apprend en réalité à reconnaître la neige en arrière-plan, parce que celle-ci accompagne presque toutes les images de loups dans le jeu d'entraînement : en présence d'une corrélation aussi simple, le modèle exploite l'indice le plus accessible plutôt que la caractéristique réellement structurante de l'objet. Ce comportement, appelé *shortcut learning*, conduit à un modèle apparemment performant en entraînement mais qui s'effondre dès que la corrélation accessoire disparaît ou s'inverse dans les données réelles. Ce mémoire étudie des stratégies de régularisation explicative qui visent à prévenir ce phénomène en contraignant, pendant l'entraînement, la zone de l'image sur laquelle le modèle s'appuie pour décider.

Deux hypothèses sont posées *a priori* : (i) ces stratégies permettent d'améliorer la précision de classification par rapport à un entraînement non régularisé, et (ii) elles permettent d'atteindre des performances comparables avec moins d'images d'entraînement.

Quatre stratégies sont comparées à une *baseline* non régularisée : Double Backpropagation, Right for the Right Reasons (RRR), Guided Attention Inference Network (GAIN) et Guided GradCAM sur laquelle notre analyse se focalise.

L'évaluation porte sur trois axes : la précision de classification, l'alignement entre la carte Grad-CAM et une zone d'explication de référence, et la capacité à empêcher l'apprentissage d'un raccourci explicitement construit. Elle s'appuie sur un dataset synthétique de relations géométriques, où la « bonne » explication est connue par construction, puis est prolongée sur deux datasets réels (CUB-200-2011 et un Fish Dataset), avec une architecture simple entraînée *from scratch* complétée par un ResNet18 pré-entraîné.

Sur la précision de classification, les quatre stratégies offrent de bonnes performances, avec un léger avantage pour Guided GradCAM. L'écart est en revanche bien plus marqué, par rapport à la *baseline*, sur l'alignement entre la carte Grad-CAM produite et la zone d'explication attendue, mesuré par l'IoU avec un masque de référence, pour le dataset synthétique comme pour les datasets réels. Le constat le plus marquant vient toutefois de l'expérience centrale du mémoire : lorsqu'une flèche est corrélée à la classe en entraînement mais que cette corrélation s'inverse en test, la *baseline* chute à 15,67 % de précision de test, soit nettement sous le hasard, alors que Guided GradCAM, avec une pondération suffisante, restaure la précision à 84,00 % et équilibre les performances sur les images avec et sans flèche. L'analyse qualitative des cartes Grad-CAM confirme que la zone d'attention cesse de se porter sur la flèche.

En revanche, l'hypothèse selon laquelle Guided GradCAM permettrait d'atteindre, avec moins d'images, les performances d'un modèle non régularisé entraîné sur l'ensemble du jeu n'est pas confirmée : l'avantage observé sur le dataset synthétique se concentre sur des tailles intermédiaires d'entraînement et disparaît aux tailles les plus faibles, et les résultats correspondants sur les datasets réels restent peu concluants.

Mots-clés : Apprentissage profond, XAI, Grad-CAM, Vision par ordinateur.

Code source disponible sur GitHub : <https://github.com/NicolasMelaerts/Memoire-fin-etude.git>.